

배터리 Cycle Life EDA 및 모델 설계 보고서

1. 분석 범위와 핵심 결론

분석 대상은 셀 141개와 사이클별 측정값 117,775행이며, 이 중 최종 수명인 `cycle_life`가 기록된 셀은 129개이다. 중복된 셀과 중복된 (`cell`, `cycle`) 기록은 없었다.

핵심 결론은 다음과 같다.


1. 관측된 Cycle Life는 392~1,935 cycles이며, 결측 12개를 제외한 129개 중 단수명 28개, 중수명 65개, 장수명 36개이다. 배치별 분포 차이가 매우 커서 배치를 무시한 무작위 분할은 성능을 과대평가할 수 있다.
2. QDischarge는 초반에 거의 평탄하거나 소폭 변한 뒤 수명 후반에 급격히 감소한다. 자동 탐지한 knee point의 중앙값은 단수명 347.5, 중수명 632.0, 장수명 885.5 cycles이며, 대체로 최종 수명의 77~79% 부근이다.
3. 초기 10→100 cycle의 $\Delta Q(V)$ 는 단수명 셀에서 더 큰 음의 변화가 나타났다. 전체 셀에서 `dq_min`과 수명의 Pearson 상관은 0.8273, `dq_std`는 -0.8235, `dq_range`는 -0.7999, `dq_mean`은 0.7974로 가장 강했다.
4. C-rate와 수명은 단순한 단조 관계가 아니다. 최대 C-rate와 수명의 상관은 -0.2595에 그쳤고, 같은 명목 프로토콜이라도 `newstructure` 여부에 따라 평균 수명이 크게 달랐다. 따라서 “고속 충전이 수명을 짧게 만든다”는 인과 결론은 현재 결과만으로 지지되지 않는다.
5. 과제의 주 모델은 Regression으로 정의하고, 연속형 `cycle_life`를 target으로 사용한다. 1차 모델은 Ridge, 비교 모델은 ElasticNet과 HistGradientBoosting을 권장한다. 검증은 셀 단위로 수행하고, 일반 무작위 교차검증과 배치 외 부검증을 함께 보고해야 한다.

2. 데이터 품질과 분석 전제

항목	실행 결과	분석상 처리
셀 단위 데이터	141행 × 8열	한 셀을 하나의 표본으로 사용
사이클 요약 데이터	117,775행 × 11열	초기 2~100 cycle 집계에 사용
<code>cycle_life</code> 결측	12개	지도학습 및 수명 그룹 비교에서 제외
셀 키 중복	0개	일대일 결합 가능
(<code>cell_key</code> , <code>cycle</code>) 중복	0개	사이클 중복 집계 문제 없음
$\Delta Q(V)$ 계산	141/141 성공	ΔQ 통계량은 전체 셀에서 생성 가능
IR 초기 feature 결측	9개	학습 fold 안에서만 대체 필요

Cycle 1의 모든 측정값이 0인 셀은 46개이며 모두 2017-05-12 배치에 속한다. 전체 141개 중 32.62%에서 QDischarge, QCharge, Tmax, Tavg, chargetime의 cycle 1 값이 0이었다. 다른 배치의 cycle 1은 0이 아니므로, 이를 모든 데이터에 공통으로 사용된 초기화 값이라고 단정할 수 없다. 초기 feature를 만들 때는 cycle 1을 제외하고 `cycle > 1`의 유효한 측정값을 사용했다. 이 0값이 2017-05-12 배치만의 저장 방식인지 여부는 원본 실험 문서로 추가 확인해야 한다.

3. Q1 Cycle Life 분포는 어떻게 생겼는가



먼저 예측 대상인 `cycle_life`가 어느 범위에 분포하는지 확인했다. 수명이 특정 구간에 몰려 있는지, 단수명과 장수명 셀의 비율은 어떤지, 다른 셀과 유난히 다른 셀이 있는지를 알아야 이후 분석과 모델 평가 방법을 정할 수 있기 때문이다.


3.1 전체 분포와 그룹 비율

- 실제 관측 범위는 392~1,935 cycles이다. 분석 그래프의 범위를 150~2,300 cycles로 설정했으며, 모든 유효 관측치가 이 범위 안에 포함된다.
- 수명 그룹은 요구사항에 맞춰 단수명 <500, 중수명 500~1,000, 장수명 >1,000으로 해석한다. 실제 데이터에는 정확히 500 cycles인 셀이 없으므로 코드의 경계 포함 방식은 현재 그룹 개수와 비율에 영향을 주지 않는다.
- 집계 결과는 단수명 28개, 중수명 65개, 장수명 36개이며, `cycle_life`가 없어 분류할 수 없는 셀은 12개이다.

그룹	개수	전체 141개 기준	수명 유효 129개 기준
단수명	28	19.86%	21.71%
중수명	65	46.10%	50.39%
장수명	36	25.53%	27.91%
<code>cycle_life</code> 결측	12	8.51%	제외

즉 유효 target 기준으로 장수명은 27.91%, 단수명은 21.71%이며, 장수명:단수명 비는 약 1.29:1이다. 전체 분포는 400~1,200 cycles에 대부분 모이지만 1,600~1,935 cycles의 오른쪽 꼬리가 존재한다.

3.2 배치별 차이



상자그림의 가운데 선은 각 배치의 중앙값을, 점은 개별 셀의 수명을 나타낸다. 2018-02-20의 점들은 주로 낮은 수명 구간에 모여 있고, 2018-04-12는 더 높은 구간까지 넓게 분포한다. 전체 히스토그램만으로는 보이지 않았던 배치 간 차이를 확인할 수 있다.

배치	유효 n	평균	중앙값	최소	최대	단수명/중수명/장수명
2017-05-12	46	844.7	858.5	534	1,227	0 / 36 / 10
2018-02-20	39	565.7	472.0	392	1,186	28 / 8 / 3
2018-04-12	44	1,059.7	1,005.5	541	1,935	0 / 21 / 23
2018-04-03 varcharge	0	—	—	—	—	cycle_life 없음

2018-02-20은 유효 셀의 71.79%가 단수명인 반면, 2018-04-12는 52.27%가 장수명이다. 이 정도의 분포 이동은 배치가 protocol·구조·실험 시점과 얽힌 강한 교란 요인일 가능성을 보여 준다.

3.3 이상치 셀과 유독 짧은 셀

IQR은 같은 배치 안에서 대부분의 셀이 모여 있는 범위를 구한 뒤, 그 범위에서 유난히 멀리 떨어진 셀을 찾는 방법이다. 여기서 이상치는 “문제가 있는 셀”이라는 뜻이 아니라 같은 배치의 다른 셀과 수명이 많이 다른 셀이라는 뜻이다. 따라서 유난히 짧은 셀뿐 아니라 유난히 오래 사용된 셀도 이상치 후보가 될 수 있다. 이번 결과에서는 후보가 긴 수명 쪽에 몰렸다.

- 2018-02-20: 777~1,186 cycles의 9개 셀이 상한 612를 초과했다.
- 2018-04-12: 1,801, 1,836, 1,935 cycles의 3개 셀이 상한 1,646.125를 초과했다.
- 예를 들어 2018-02-20 배치는 대부분 400~500 cycles 부근에 모여 있다. 따라서 777 cycles도 전체 데이터에서는 아주 긴 값이 아닐 수 있지만, 이 배치 안에서는 다른 셀보다 훨씬 긴 값이어서 후보로 잡힌다.
- 이 결과만으로 측정 오류라고 판단할 수 없으므로 자동 삭제하면 안 된다. 오히려 이 셀들이 다른 충전 방법이나 다른 구조를 사용했는지 확인해야 한다.

최단 수명 셀은 2018-02-20_cell_20의 392 cycles이다. 이 셀은 $\Delta Q(V)$ 그래프에서 약 2.9 V 부근의 변화량이 약 -0.066 Ah까지 내려갔다. 비교한 다른 단수명 셀보다 초기 10→100 cycle 사이의 용량 변화가 더 컸다는 뜻이다. 다만 이 그래프만으로 “왜 빨리 수명이 끝났는지”까지 알 수는 없다. 같은 충전 방법을 사용한 다른 셀도 비슷했는지,

사용 중 온도가 더 높았는지, 내부저항이 달랐는지, 측정이 중간에 잘못 끝난 것은 아닌지를 추가로 확인해야 한다.

3.4 핵심 해석과 모델링 시사점


핵심 확인 결과: 전체 수명은 392~1,935 cycles로 범위가 넓다. 특히 배치별 차이가 컸다. 2018-02-20에는 단수명 셀이 많이 모여 있지만, 2018-04-12에는 장수명 셀이 절반 이상 포함되어 있다. 즉 모든 배치가 비슷한 조건에서 만들어진 동일한 집단이라고 보기 어렵다.

해석: 데이터를 무작위로만 나누면 같은 배치의 비슷한 셀이 학습 데이터와 평가 데이터에 함께 들어갈 수 있다. 그러면 모델이 배터리의 열화 특징을 배운 것이 아니라 “이 배치의 셀은 대체로 수명이 짧다”는 배치 특성을 외워서 점수가 높게 나올 수 있다. 또한 IQR 후보는 잘못된 데이터가 아니라, 오래 사용할 수 있었던 특별한 조건을 가진 셀일 가능성도 있다.

모델링 시사점: 예측값은 Short/Middle/Long 같은 등급보다 실제 cycle 수로 출력하는 회귀 방식이 적합하다. 모델 평가는 데이터를 무작위로 나눈 결과뿐 아니라, 한 배치를 통째로 빼고 학습한 뒤 빠진 배치를 예측하는 방식으로도 진행한다. 이렇게 해야 처음 보는 배치에서도 모델이 작동하는지 확인할 수 있다. IQR 후보는 바로 삭제하지 않고 원래 측정 기록을 확인한 뒤 처리한다.

추가 확인: `cycle_life` 결측 12개가 특정 배치(protocol)에 집중되는지, 최단 수명 셀의 실험 중단 또는 센서 이상 여부를 확인해야 한다.

4. Q2 방전 용량은 어떻게 감소하는가



Q1에서는 셀마다 최종 수명이 크게 다르다는 사실을 확인했다. 다음으로 단수명 셀과 장수명 셀이 실제 사용 과정에서도 서로 다른 방식으로 열화되는지 살펴봤다. 이를 위해 cycle이 증가할 때 방전 가능한 용량인 QDischarge가 언제부터, 얼마나 빠르게 감소하는지 비교했다.

4.1 열화 형태


대표 셀 곡선은 세 그룹 모두에서 대체로 다음 형태를 보인다.

1. 초기에는 QDischarge가 거의 일정하거나 약간 증가한다.
2. 중기에는 완만한 감소가 이어진다.
3. 후기에는 곡률이 커지며 급격한 하강이 나타난다.

초기 2~100 cycle의 평균 기울기는 세 그룹 모두 출력 정밀도에서 거의 0 Ah/cycle이었으나, 마지막 100개 관측의 평균 기울기는 단수명 -0.0020, 중수명 -0.0010, 장수명 -0.0007 Ah/cycle이었다. 따라서 열화 속도는 일정하지 않고 후반에 가속되며, 단수명 셀일수록 마지막 구간의 하강이 더 가파르다.

4.2 Knee point

Knee point를 찾기 위해 작은 측정 흔들림이 결과에 지나치게 영향을 주지 않도록 곡선을 부드럽게 정리했다. 그다음 완만하게 감소하던 방전 용량이 급격히 떨어지기 시작하는 지점을 찾았다. 이 전환점을 knee point라고 한다.



각 곡선의 세로 점선이 계산된 knee point다. 단수명 셀은 약 300~400 cycles, 중수명 셀은 약 500~700 cycles, 장수명 셀은 약 800~900 cycles 부근에서 급격한 하강이 시작되는 모습을 볼 수 있다. 셀마다 정확한 위치는 다르지만, 수명이 긴 셀일수록 전환점이 뒤로 이동하는 흐름이 나타난다.

수명 그룹	knee 평균 cycle	knee 중앙값 cycle	중앙 수명 비율	평균 수명 비율
단수명	345.4	347.5	0.7711	0.7688
중수명	607.4	632.0	0.7720	0.7700
장수명	926.9	885.5	0.7890	0.7612

절대 knee cycle은 수명 그룹에 따라 커지지만, 최종 수명에 대한 비율은 대체로 0.77 전후였다. 장수명 그룹은 최소 비율이 0.3545이고 표준편차가 0.1196으로 다른 그룹보다 변동이 컸다. 자동 검출 실패·비정상 곡선 가능성을 개별 시각 점검해야 한다.

데이터 누수 주의: knee와 마지막 100 cycle 기울기는 셀의 전체 미래 궤적을 사용한다. 열화 현상을 설명하는 EDA에는 유효하지만, 초기 100 cycle 기반 수명 예측 feature로 사용하면 안 된다.

4.3 핵심 해석과 모델링 시사점


핵심 확인 결과: 방전 용량은 전 수명에 걸쳐 일정한 속도로 감소하지 않는다. 초기에는 변화가 작지만 수명 후반부에 하강 속도가 커지며, 마지막 100 cycle의 평균 기울기는 단수명 셀이 장수명 셀보다 약 세 배 가파르다. knee의 절대 위치는 수명이 긴 셀일수록 뒤로 이동하지만, 대체로 최종 수명의 77~79% 부근에서 나타난다.

해석: 처음의 방전 용량이 얼마였는지만 보는 것보다, 시간이 지나면서 용량이 어떤 모양으로 줄어드는지를 함께 보는 것이 수명을 이해하는 데 더 중요할 수 있다. 그러나 knee와 마지막 구간의 감소 속도는 배터리를 거의 끝까지 사용한 뒤에야 알 수 있다. 따라서 “초기 데이터로 미리 수명을 예측한다”는 목적에는 사용할 수 없다.

모델링 시사점: 모델에는 처음 100 cycles 안에서 알 수 있는 평균 방전 용량, 초기 감소 속도, 10→100 cycle 변화량만 후보로 넣는다. 변수를 하나씩 빼거나 추가하면서 실제 예측 성능이 좋아지는지도 확인한다. knee와 마지막 100 cycle의 감소 속도는 미래 정보를 사용하므로 모델 입력에서 제외한다. 단순한 직선 기울기로 잡히지 않는 변화는 $\Delta Q(V)$ 와 트리 기반 모델이 보완할 수 있는지 비교한다.

추가 확인: 장수명 그룹에서 비정상적으로 이른 knee가 검출된 셀은 자동 탐지 오류인지 원시 곡선으로 확인해야 한다. 초기 slope가 출력 정밀도에서 0에 가까우므로 더 높은 소수점 정밀도와 robust slope로 재계산할 필요도 있다.

5. Q3 $\Delta Q(V)$ 에서 초기 차이가 보이는가



Q2의 전체 열화곡선은 단수명과 장수명 셀의 차이를 보여 주지만, 배터리를 거의 끝까지 사용해야 확인할 수 있다는 한계가 있다. 따라서 cycle 10과 100처럼 비교적 초기의 두 시점만으로 장기 수명 차이를 발견할 수 있는지 확인했다.

전압별 방전 용량이 cycle 10에서 100 사이에 얼마나 변했는지를 $\Delta Q(V) = Q_{100}(V) - Q_{10}(V)$ 로 계산했다. 대표 셀을 3개씩 비교한 결과, 단수명 평균 곡선은 약 3.0 V 부근에서 -0.051 Ah, 장수명 평균 곡선은 약 2.9 V 부근에서 -0.024 Ah 수준까지 내려갔다. 단수명 대표 셀에서 초기 용량 변화가 더 크게 나타난 것이다. 이 두 값은 그래프에서 읽은 근사치이며 대표 셀 3개씩의 평균이므로, 전체 셀의 차이를 확정하는 값으로 해석하지는 않는다.

전체 141개 셀의 ΔQ 통계 추출은 모두 성공했다. 수명과의 상관은 다음과 같다.

ΔQ feature	Pearson r with Cycle Life	해석
dq_min	0.8273	최소값이 덜 음수일수록 수명이 긴 경향
dq_std	-0.8235	곡선 변동이 클수록 수명이 짧은 경향
dq_range	-0.7999	변화 범위가 클수록 수명이 짧은 경향
dq_mean	0.7974	평균 변화가 덜 음수일수록 수명이 긴 경향
dq_variance	-0.7498	분산이 클수록 수명이 짧은 경향
dq_max	0.3831	비교적 중간 정도의 양의 관계
dq_kurtosis	0.3647	곡선 모양 정보가 일부 관계를 보임
dq_skewness	-0.0257	선형 관계가 거의 없음

ΔQ 관련 값들은 수명과 관계가 강하지만, 서로 거의 같은 내용을 반복해서 나타낸다. 예를 들어 dq_std, dq_min, dq_range 사이의 상관은 모두 0.98 이상이다. 특히 dq_range는 dq_max - dq_min으로 계산되므로 세 값을 함께 넣으면 같은 정보를 여러 번 넣는 셈이다. 이렇게 비슷한 변수가 많으면 모델이 어떤 변수를 중요하게 사용했는지 설명하기 어려워지고, 새로운 데이터에서 결과가 불안정해질 수 있다. 따라서 기본 모델에는 dq_min 하나를 대표값으로 사용하고, 곡선 모양을 보여 주는 dq_kurtosis를 보조로 추가한다. 나머지 ΔQ 값은 dq_min 대신 넣었을 때 성능이 더 좋아지는지를 각각 비교한다.

추가 가설검증: 그래프에서 보이는 차이가 우연인지 확인하려면 단수명과 장수명 셀 전체의 dq_min을 통계적으로 비교해야 한다. 데이터가 정규분포라고 보기 어려우므로 Mann-Whitney U 검정이나 permutation test를 사용할 수 있다. 차이가 “얼마나 큰지”를 보여 주는 효과크기도 함께 제시한다. 이번 단계에서는 이 검정을 수행하지 않았으므로, 현재 결과만으로 차이가 통계적으로 확실하다고 단정하지 않는다.

5.1 핵심 해석과 모델링 시사점

핵심 확인 결과: $\Delta Q(V)$ 는 이번 EDA에서 최종 수명과 가장 강하게 연결된 초기 신호다. 대표 곡선에서도 단수명 셀의 음의 변화가 더 깊었고, 전체 셀의 통계량에서도 dq_min, dq_std, dq_range, dq_mean이 모두 절대 상관 0.79 이상을 보였다.

해석: 배터리를 끝까지 사용하지 않아도 10번째와 100번째 cycle 사이의 변화만으로 장기 수명 차이를 어느 정도 구분할 수 있다는 뜻이다. 다만 여러 ΔQ 통계값은 같은 곡선을 서로 다른 방식으로 요약한 것이므로, 상관관계수가 높다고 전부 모델에 넣을 필요는 없다.

모델링 시사점: 먼저 `dq_min`을 대표 변수로 사용한다. 곡선의 모양까지 표현하려면 `dq_kurtosis`를 추가한다. `dq_std`, `dq_range`, `dq_mean`, `dq_variance`는 모두 한꺼번에 넣지 않고, `dq_min` 대신 하나씩 바꿔 넣어 어떤 조합이 실제 평가 데이터에서 가장 잘 작동하는지 확인한다. 이 선택은 전체 데이터를 미리 보고 결정하지 않고, 매 학습 과정 안에서만 수행한다.

추가 확인: 대표 셀 3개씩의 시각적 차이가 전체 그룹에서도 유지되는지 비모수 검정과 효과크기로 확인해야 한다. 배치별로 ΔQ -수명 관계를 다시 계산해 강한 전체 상관이 배치 차이만 반영한 것은 아닌지도 점검해야 한다.

6. Q4 충전 조건과 수명의 관계

앞에서 확인한 수명 차이가 충전 방법 때문에 발생했을 가능성도 살펴봤다. 충전 속도가 빠르면 항상 수명이 짧아지는지, 아니면 충전 속도 외에 전환 시점과 셀 구조 같은 조건이 함께 작용하는지를 확인하는 단계다.

6.1 프로토콜별 평균 수명


충전 프로토콜별로 셀 수, 평균 수명, 표준편차와 범위를 계산했다. 평균 수명이 높은 일부 조건과 낮은 일부 조건은 다음과 같다.

프로토콜	n	평균 수명	표준편차	범위
4.8C(80%)-4.8C-newstructure	11	1,333.3	419.1	777~1,836
4C(80%)-4C	2	1,226.5	0.7	1,226~1,227
3.6C(80%)-3.6C	3	1,182.0	7.0	1,177~1,190
5C(67%)-4C-newstructure	7	1,105.7	402.9	813~1,935
5.3C(54%)-4C-newstructure	8	1,074.4	129.7	935~1,315
5.2C(58%)-4C	4	477.8	18.5	452~493
5.2C(50%)-4.25C	5	454.0	20.9	424~474
4.65C(69%)-6C	2	452.0	11.3	444~460
5.6C(26%)-4.5C	6	448.5	29.1	412~491
3.6C(30%)-6C	2	421.0	7.1	416~426
3.6C(9%)-5C	2	394.5	2.1	393~396

일부 충전 방법은 해당 셀이 1~2개밖에 없다. 셀이 두 개뿐인 조건에서 평균 수명이 높게 나왔다고 해서 그 충전 방법이 항상 좋다고 결론 내릴 수는 없다. 특히 충전 속도가 같아도 배터리 구조가 달라지면 평균 수명이 크게 달랐다.

- 4.8C(80%)-4.8C: 표준 구조 평균 560.6(n=7) vs newstructure 평균 1,333.3(n=11)
- 5.2C(58%)-4C: 표준 구조 평균 477.8(n=4) vs newstructure 평균 961.7(n=3)
- 5.6C(26%)-4.5C: 표준 구조 평균 448.5(n=6) vs newstructure 평균 991.3(n=3)

6.2 고속 충전 셀이 정말 짧은가



C-rate와 Cycle Life의 관계

왼쪽은 첫 번째 충전 단계의 C-rate, 오른쪽은 충전 과정에서 사용된 최대 C-rate와 수명의 관계다. 같은 C-rate에서도 수명이 넓게 퍼져 있고, 점의 색과 모양으로 구분한 배치에 따라 위치가 달라진다. 따라서 충전 속도가 높을수록 수명이 일정하게 감소하는 단순한 관계는 확인되지 않는다.

전체 수명과의 Pearson 상관은 첫 단계 C-rate -0.0783, 최대 C-rate -0.2595였다. 첫 단계 C-rate의 선형 관계는 거의 없고, 최대 C-rate도 약한 음의 관계에 그친다. 산점도에서는 같은 C-rate에서도 배치에 따라 수명이 크게 갈라진다. 따라서 현재 데이터는 “C-rate가 높을수록 반드시 짧다”는 단순 가설을 지지하지 않는다.

C-rate 하나만으로는 실제 충전 전류 패턴 전체를 설명하기 어렵다. 충전 속도를 바꾸는 SOC, 두 번째 단계의 C-rate, *newstructure*, *slowcycle*, 배치가 함께 달라지기 때문이다. 현재는 C-rate와 최종 수명의 관계까지 확인했으며, C-rate와 QDischarge·IR·온도의 초기 변화 속도를 직접 비교하는 분석은 추가로 필요하다.

권장 가설검증: 충전 속도만의 영향을 확인하려면 같은 배치와 같은 구조 안에서 충전 속도가 다른 셀을 비교해야 한다. 각 조건의 셀 수가 적고 서로 다르므로 일반적인 평균 비교보다는 permutation test처럼 작은 표본에서도 사용할 수 있는 방법이 적절하다. 여러 충전 방법을 동시에 비교하면 우연히 차이가 커 보이는 경우가 늘어나므로 이를 보정해야 한다. 다만 특정 충전 속도가 특정 구조나 배치에만 사용되었다면, 현재 데이터만으로 충전 속도와 구조의 영향을 완전히 분리할 수 없다.

6.3 핵심 해석과 모델링 시사점

핵심 확인 결과: 첫 단계 C-rate와 수명의 상관은 -0.0783, 최대 C-rate는 -0.2595로 약했다. 반면 동일한 명목 C-rate에서도 *newstructure* 여부에 따라 평균 수명이 약 두 배까지 달라졌다.

해석: 수명은 “몇 C로 충전했는가” 하나만으로 결정되지 않는다. 어느 충전량에서 속도를 바꿨는지, 두 번째 단계에서는 얼마나 빠르게 충전했는지, 배터리 구조가 달랐는지, 중간에 느린 충전 cycle을 사용했는지가 함께 영향을 줄 수 있다. 따라서 현재 그래프만 보고 고속 충전 때문에 수명이 짧아졌다고 말할 수 없다.


모델링 시사점: 긴 충전 방법 이름을 그대로 모델에 넣지 않고, 첫 번째 충전 속도, 두 번째 충전 속도, 속도를 바꾸는 시점, 배터리 구조, 느린 충전 사용 여부로 나누어 입력한다. 현재 계산된 값 중에서는 *max_c_rate*를 우선 후보로 사용하지만, 이 값 하나만으로 수명을 잘 예측할 것이라고 기대하지는 않는다. 모델 평가는 특정 배치나 충전 방법을 통째로 제외했을 때도 성능이 유지되는지 확인한다.

추가 확인: 충전 전류 패턴과 초기 QDischarge·IR·온도 변화율의 관계를 직접 계산해야 한다. 동일 구조와 유사한 전환 SOC 안에서 C-rate만 달라지는 비교군이 충분한지도 확인해야 한다.

7. Q5 어떤 신호가 수명과 연관되어 있는가

마지막으로 앞에서 만든 초기 feature 중 실제로 *cycle_life*와 관계가 큰 신호가 무엇인지 비교했다. 동시에 같은 정보를 반복해서 담는 feature가 있는지도 확인해, 모델에 넣을 후보를 줄였다.

7.1 수명과의 상관 순위



초기 feature와 Cycle Life의 상관관계

막대가 오른쪽으로 길수록 해당 feature가 커질 때 수명도 길어지는 경향이 있고, 왼쪽으로 길수록 feature가 커질 때 수명이 짧아지는 경향이 있다. 절대 길이가 긴 feature일수록 수명과 선형 관계가 강하다. ΔQ 관련 feature가 가장 긴 막대를 보여 초기 수명 예측의 우선 후보가 되었고, C-rate와 일부 기울기 feature는 상대적으로 관계가 약했다.

순위	초기 feature	Pearson r	선정 판단
1	dq_min	0.8273	대표 ΔQ 크기 feature로 채택
2	dq_std	-0.8235	dq_min과 중복되어 대체 후보
3	dq_range	-0.7999	결정적 중복 관계로 baseline 제외
4	dq_mean	0.7974	ΔQ 대체 후보
5	dq_variance	-0.7498	ΔQ 대체 후보
6	initial_QDischarge	-0.5249	QDischarge 대표 후보
7	QDischarge_mean_100	-0.5003	초기값과 비교해 하나만 선택
8	dq_max	0.3831	dq_range와 함께 사용 금지
9	dq_kurtosis	0.3647	ΔQ 모양 보완 후보
10	temperature_slope_100	0.3455	온도 동역학 후보
11	IR_mean_100	-0.3356	내부저항 수준 후보, 결측 9개
12	max_c_rate	-0.2595	protocol 요약 후보

그 밖에 Tavg_mean_100 0.2387, chargetime_mean_100 -0.1941이었다.

QDischarge_cycle100_minus_cycle10 -0.0231, IR_slope_100 0.0531, Tmax_mean_100 -0.0168은 단변량 선형 관계가 거의 없었다. 다만 상관이 낮아도 비선형 모델에서 상호작용 정보가 있을 수 있으므로, train fold 내부의 ablation으로 최종 판단한다.

7.2 Multicollinearity 해석

중복 묶음	근거	처리 원칙
ΔQ 크기 통계	쌍별 절대 상관 0.9310~0.9913, VIF 25.9~324.9	dq_min 1개를 우선 선택
dq_min, dq_max, dq_range	range=max-min, VIF 약 1.0×10^{15}	세 변수 동시 투입 금지
초기 QDischarge vs 100-cycle 평균	절대 상관 0.9667, VIF 111.1/124.6	둘 중 하나만 선택
first-stage vs max C-rate	절대 상관 0.8827, VIF 7.36/9.06	max_c_rate 우선 또는 규제 사용

VIF는 한 변수가 다른 변수들과 얼마나 비슷한 정보를 가지고 있는지를 보여 주는 값이다. 값이 크다고 무조건 삭제하는 것은 아니지만, $dq_range = dq_max - dq_min$ 처럼 계산식상 겹치는 변수는 함께 사용할 이유가 없다. Ridge나 ElasticNet은 비슷한 변수가 있을 때 일반 선형회귀보다 안정적이지만, 그렇더라도 같은 정보를 담는 변수를 너무 많이 넣으면 결과 설명이 어려워진다.

7.3 핵심 해석과 모델링 시사점

핵심 확인 결과: 변수 하나씩 수명과 비교했을 때 ΔQ 관련 값의 관계가 가장 강했다. 그다음으로 초기 방전 용량, 온도 변화, 평균 내부저항이 후보로 나타났다. 하지만 ΔQ 관련 값끼리, 그리고 초기 방전 용량 관련 값끼리는 서로 매우 비슷했다.

해석: 상관계수가 높은 변수를 많이 넣는다고 항상 좋은 모델이 되는 것은 아니다. 비슷한 변수 여러 개보다, 용량 변화·내부저항·온도·충전 조건처럼 서로 다른 정보를 대표하는 변수를 고르는 편이 낫다. 중복 변수를 모두 넣으면 학습 데이터에서는 잘 맞더라도 새로운 배치에서는 결과가 흔들릴 수 있다.

모델링 시사점: 처음에는 ΔQ 크기, 방전 용량, 내부저항, 온도, 충전시간, 충전 조건에서 대표 변수 하나씩만 골라 간단한 모델을 만든다. 그다음 변수 묶음을 하나씩 추가하거나 빼면서 평가 점수가 실제로 좋아지는지 확인한다. 선형 모델에는 Ridge 또는 ElasticNet을 사용한다. 트리 모델은 변수 중요도가 데이터 분할마다 크게 바뀌지 않는지도 함께 확인한다.

추가 확인: Pearson 상관은 두 값이 직선 형태로 함께 변하는지만 보여 준다. 곡선 형태의 관계나 배치 차이를 제외한 뒤에도 관계가 남는지는 추가 분석이 필요하다. 데이터를 여러 번 나누어 학습했을 때 같은 변수가 반복해서 선택되는지도 확인해야 한다.

8. 모델 설계 전략

8.1 Feature Engineering과 객관적 선별

모든 predictor는 실제 예측 시점에 사용 가능한 cycle 2~100 정보만으로 계산한다.

권장 최소 feature set

영역	feature	객관적 근거
ΔQ 크기	dq_min	target과 가장 강한 상관 $r=0.8273$
ΔQ 모양	dq_kurtosis	$r=0.3647$, VIF 4.66로 보완 정보 가능
용량 수준	initial_QDischarge 또는 QDischarge_mean_100	각각 $r=-0.5249/-0.5003$, 둘 사이 절대 상관 0.9667
내부저항	IR_mean_100	$r=-0.3356$, VIF 4.43; 결국 9개 대체 필요
온도 동역학	temperature_slope_100	$r=0.3455$, VIF 2.22
충전시간	chargetime_mean_100	$r=-0.1941$, VIF 1.95
충전 조건	max_c_rate	first-stage보다 target 상관 큼; 구조/SOC 정보 별도 필요

batch는 모델의 일반 입력값으로 바로 사용하기보다, 새로운 실험 묶음에서도 모델이 잘 작동하는지 평가할 때 사용한다. 배치 번호를 입력값으로 주면 모델이 배터리 상태보다 “어느 배치인가”를 외울 수 있기 때문이다. 충전 방법 이름

인 `policy_readable`도 그대로 넣지 않는다. 첫 번째·두 번째 충전 속도, 속도 전환 시점, 배터리 구조, 느린 충전 사용 여부처럼 의미가 분명한 값으로 나누어 사용한다. 현재 만들어진 값은 첫 번째 C-rate와 최대 C-rate이며, 나머지 항목은 추가로 가공해야 한다.

누수로 제외할 feature

- knee cycle 및 knee life fraction
- 마지막 100 cycle QDischarge slope
- 최종 수명을 알아야 정의되는 모든 비율·후기 통계
- 전체 데이터에서 미리 계산한 대치값, scaling, feature selection 결과

8.2 Regression 선택과 Target 정의

과제의 주 문제는 회귀로 정의한다.

- Target: 셀별 최종 `cycle_life(cycles)`
- 이유: 원래 target이 392~1,935 사이의 연속 수치이며, Short/Middle/Long으로 바꾸면 그룹 내부의 순서와 예측 오차 크기 정보가 사라진다.
- EDA의 수명 그룹은 설명과 총화 확인에만 사용한다.
- 매우 긴 수명의 셀 때문에 예측 오차가 한쪽에서 유난히 커지는 경우에는 `log(cycle_life)`로 변환한 모델도 비교한다. 아직 실제 모델의 예측 오차를 계산하지 않았으므로 로그 변환이 필요하다고 미리 결정하지 않는다.

8.3 후보 모델과 선정 논리

후보 모델은 단순히 여러 알고리즘을 나열하는 방식이 아니라, EDA에서 확인된 데이터 특성에 대응하도록 구성한다.

아래 표는 “데이터에서 무엇을 발견했는지”, “그 때문에 어떤 문제가 생길 수 있는지”, “어떤 모델이나 평가 방법으로 대응할지”를 연결한 것이다.

EDA에서 확인한 내용	예상되는 모델링 문제	대응 전략	연결되는 후보 모델
유효 셀이 129개로 적음	복잡한 모델이 학습 데이터를 외울 수 있음	단순 모델부터 시작하고 복잡도를 제한	Linear, Ridge, ElasticNet
ΔQ 와 QDischarge 변수에 비슷한 값이 많음	같은 정보를 여러 번 학습해 결과가 흔들릴 수 있음	대표 변수만 선택하고 규제를 적용	Ridge, ElasticNet
ΔQ ·온도·IR의 관계가 직선이 아닐 수 있음	선형모델이 복잡한 관계를 놓칠 수 있음	복잡도를 제한한 트리 모델과 비교	HistGradientBoosting, Random Forest
배치마다 수명 분포가 크게 다름	무작위 분할 점수가 실제보다 높게 나올 수 있음	한 배치를 통째로 제외한 평가도 시행	모든 후보 모델에 공통 적용
충전 방법별 셀 수가 적고 서로 다름	일부 충전 방법을 모델이 외울 수 있음	충전 방법을 속도·구조 등의 값으로 분해	Ridge, ElasticNet, 제한된 boosting
초기 100 cycle만 사용	미래 정보를 잘못 넣으면 성능이 부풀려짐	모든 전처리를 학습 데이터 안에서만 수행	모든 후보 모델에 공통 적용

1 DummyRegressor

모든 셀에 학습 데이터의 중앙값 수명을 동일하게 예측하는 가장 단순한 기준이다. 다른 모델이 이 모델보다도 오차를 줄이지 못한다면, 만든 feature에 수명 예측 정보가 충분하지 않거나 데이터가 너무 적다는 뜻이다. 최종 모델 후보라기보다 비교의 출발점이다.

2 Linear Regression

각 feature가 변할 때 수명이 얼마나 증가하거나 감소하는지 직선 관계로 설명하는 기본 모델이다. 결과를 이해하기 쉽다는 장점이 있다. 다만 비슷한 feature가 많으면 각 변수의 영향값이 크게 흔들릴 수 있으므로, 이 모델의 계수를 최종적인 변수 중요도라고 단정하지 않는다.

3 Ridge Regression — 1차 권장 모델

Ridge는 비슷한 feature가 여러 개 있을 때 특정 변수의 영향이 지나치게 커지지 않도록 조절하는 선형 모델이다. 이번 데이터는 셀이 129개로 적고, ΔQ 와 QDischarge 관련 값들이 서로 매우 비슷하다. 따라서 일반 선형회귀보다 결과가 안정적일 가능성이 높다. 설명하기도 비교적 쉬워 주 모델 후보로 둔다.

4 ElasticNet

ElasticNet은 비슷한 feature가 많을 때 중요하지 않은 변수의 영향값을 0으로 만들어 변수 수를 줄일 수 있다. Ridge와 예측 성능이 비슷하면서 더 적은 변수만 사용한다면 결과를 더 간단하게 설명할 수 있다. 다만 데이터를 나눌 때마다 선택되는 변수가 계속 바뀐다면 안정적이지 않은 것이므로, 같은 변수가 반복해서 선택되는지도 확인한다.

5 HistGradientBoostingRegressor — 비선형 비교 모델

Pearson 상관과 선형모델은 주로 직선 형태의 관계를 본다. 하지만 특정 온도 이상에서만 열화가 빨라지는 것처럼 조건에 따라 관계가 달라질 수 있다. HistGradientBoosting은 이런 복잡한 관계가 실제 예측에 도움이 되는지 확인하기 위한 비교 모델이다. 데이터가 적으므로 트리를 너무 복잡하게 만들지 않고, 설정값은 학습 데이터 안에서만 조정한다.

6 Random Forest — 보조 비교 모델

Random Forest도 조건에 따라 달라지는 복잡한 관계를 학습할 수 있다. 그러나 셀이 129개뿐이므로 특정 배치나 충전 방법을 그대로 외울 위험이 있다. 따라서 주 모델이 아니라 비선형 관계가 필요한지 확인하는 보조 모델로 사용한다. 무작위 분할에서는 점수가 높더라도, 한 배치를 통째로 제외한 평가에서 성능이 크게 떨어지면 선택하지 않는다.

딥러닝이 최신 방법이라는 이유만으로 후보에 포함하지는 않는다. 이번 데이터는 유효한 셀이 129개뿐이고, 원시 시계열을 그대로 쓰는 것이 아니라 초기 100 cycles을 몇 개의 숫자로 요약해 사용한다. 이런 조건에서는 딥러닝이 학습 데이터를 외울 위험이 크고 결과를 설명하기도 어렵다. 모든 모델은 같은 데이터 분할과 같은 평가 기준으로 비교한다. 성능 차이가 크지 않다면 설명하기 쉽고 결과가 안정적인 Ridge를 우선한다.

8.4 데이터 처리와 검증 설계

1. 정답인 `cycle_life`가 없는 셀 12개는 모델 학습과 평가에서 제외한다.
2. 한 셀을 한 행으로 정리한 뒤 데이터를 나눈다. 같은 셀의 일부 cycles는 학습에, 다른 cycles는 평가에 넣는 방식은 금지한다. 같은 배터리를 이미 본 모델을 평가하는 셈이기 때문이다.
3. 결측값 채우기, 값의 크기 맞추기, 변수 선택은 매번 학습 데이터만 보고 결정한다. 평가 데이터의 정보를 미리 사용하지 않는다.
4. 기본 평가는 데이터를 여러 묶음으로 나누어 반복한다. 한 번의 우연한 분할 결과만 보고 모델을 선택하지 않는다.
5. 별도로 한 배치를 전부 제외하고, 나머지 배치로 학습한 모델이 제외된 배치를 얼마나 잘 예측하는지 확인한다.
6. 같은 충전 방법의 셀이 학습과 평가에 섞여 성능이 높아지는지도 확인하기 위해, 충전 방법 단위로 데이터를 나누는 평가를 추가한다.
7. 평균적으로 몇 cycles 틀렸는지 보여 주는 MAE, 큰 오차에 더 민감한 RMSE, 전체 변동을 얼마나 설명했는지 보여주는 R^2 를 함께 제시한다.
8. 모델 설정값은 최종 평가 데이터를 보지 않은 상태에서 선택한다.

8.5 최종 판단 기준

최종 모델은 단일 random split 점수가 아니라 다음 네 조건을 동시에 만족해야 한다.

- Dummy/Linear baseline보다 MAE와 RMSE가 일관되게 개선될 것
- batch hold-out에서도 성능 붕괴가 제한적일 것
- fold별 성능 편차가 과도하지 않을 것
- `dq_min` 등 핵심 feature의 영향 방향이 fold와 모델 사이에서 대체로 일관될 것

9. 추가 확인이 필요한 항목

1. 2018-02-20_cell_20(392 cycles)의 원시 QDischarge, IR, 온도, 충전 protocol, 실험 중단·센서 로그를 확인해 짧은 수명의 원인을 조사한다.
2. cycle 1의 0값이 2017-05-12 배치의 저장 형식 차이인지 실험 문서로 확인한다.
3. 장수명 그룹에서 knee 비율이 0.3545인 셀을 개별 검토해 자동 knee 탐지 실패 여부를 확인한다.
4. C-rate 효과는 배치·구조·전환 SOC를 통제된 분석과 permutation/비모수 검정으로 재평가한다.
5. ΔQ 그룹 차이에 대한 p-value와 효과크기, 모델의 실제 교차검증 성능은 후속 모델링에서 산출한다.

10. 최종 제안

가장 타당한 과제 제출안은 `cycle_life` 회귀로 문제를 정의하고, 초기 100 cycle에서 추출한 `dq_min`, ΔQ 모양 통계 1개, QDischarge 수준 1개, IR 평균, 온도 기울기, 충전시간 평균, 최대 C-rate를 기본 입력으로 사용하는 것이다. 다중 공선성이 큰 ΔQ 크기 통계와 QDischarge 수준 통계는 각각 대표 변수 하나만 남기고, Ridge를 주 모델로 삼아 ElasticNet 및 비선형 boosting과 비교한다. 성능은 셀 단위 교차검증과 batch hold-out을 함께 보고해야 하며, knee와 후기 slope는 EDA에만 사용하고 예측 feature에서는 제외한다.